

RAPPORT



Réalisé par Erwin, Frédéric et Hamid

1. Types de bases de données	4
2. Présentation de la structure actuelle	7
2.1 Description de l'existant	7
2.2 Problématiques identifiées	7
3. Types de structures de Data Warehouse	9
3.1 Les principales approches de conception	9
3.2 Les schémas de modélisation	12
3.3 Tableau : Comparaison des schémas de modélisation	17
4. Infrastructure associée au Data Warehouse	18
5. L'alimentation du Data Warehouse	21
5.1 ETL et ELT : deux approches d'alimentation	21
5.1.1 ETL (Extract - Transform - Load)	21
5.1.2 ELT (Extract - Load - Transform)	22
5.1.3 Tableau comparatif	23
5.2 Les étapes d'alimentation	24
5.2.1 Extraction	24
5.2.2 Transformation	24
5.2.3 Chargement	25
5.3 La qualité des données	25
5.4 Le rôle de DBT	26
5.5 Architecture recommandée pour ArtiSell	28
6. Outils d'analyses à partir du Data Warehouse	30
6.1 Outils de Business Intelligence (BI)	30
Tableaux de bord de vente Power BI	31
6.2 Outils Tableau	31
7. Gestion des droits	34
8. Maintenance et évolutivité	35
9. Ressources nécessaires à la solution	36
10. Conclusion	37
11. Sitographie	38

Dans le cadre de la modernisation du système d'information d'ArtiSell, nous avons été mandatés en tant que consultants Data Engineers juniors afin d'étudier les solutions permettant d'améliorer et optimiser l'exploitation des données de l'entreprise.

Aujourd'hui, certaines informations stratégiques, telles que le chiffre d'affaires par région, les produits les plus vendus ou encore le comportement d'achat des clients, sont difficiles à obtenir. Bien que ces données soient présentes dans les différents systèmes de l'entreprise, leur extraction nécessite des requêtes complexes et des traitements chronophages, ce qui limite la production d'indicateurs fiables et rapides pour la prise de décision.

La problématique est donc la suivante : comment mettre en place une solution décisionnelle permettant de centraliser les données d'ArtiSell et de produire des analyses fiables, performantes et facilement exploitables par les différents métiers ?

Afin de répondre à cette problématique, ce rapport présente, dans un premier temps, les concepts fondamentaux liés aux bases de données transactionnelles, aux systèmes OLAP et aux Data Warehouses. Nous analyserons ensuite la situation actuelle d'ArtiSell, avant d'étudier les différentes architectures décisionnelles, les mécanismes d'alimentation des données et les outils d'analyse disponibles. Enfin, nous aborderons les aspects liés à la sécurité, à la maintenance et à l'évolutivité de la solution proposée.

1. Types de bases de données

On distingue deux types de bases de données :

- les bases de données OLTP (pour On Line Transaction Processing) conçues pour gérer les opérations courantes et les transactions quotidiennes d'une entreprise (par exemple les données liées à une vente effectuée depuis le site de vente en ligne)
- les bases de données OLAP (pour On Line Analytical Processing) dédiées à des analyses complexes pour des choix stratégiques

Une base de données OLTP sera très efficace pour gérer des transactions rapides.

L'avantage principal d'une base de données OLAP réside dans sa capacité à fournir de l'information agrégée sans avoir à faire trop de manipulations.

Il existe plusieurs types de OLAP :

- ROLAP : stocke les données dans bases de données relationnelles et effectue une analyse multidimensionnelle dynamique. Son principal avantage est sa capacité à s'adapter à de grands volumes de données. Cependant, ses performances peuvent diminuer avec des requêtes très complexes.
- MOLAP : utilise des cubes multidimensionnels et est conçu pour fournir des réponses rapides à des requêtes prédéfinies. Bien qu'il soit agile et efficace, son évolutivité est limitée, ce qui peut constituer un problème pour les entreprises disposant de grandes quantités d'informations.
- HOLAP : HOLAP combine les avantages de ROLAP et MOLAP. Il offre un équilibre optimal entre vitesse et son évolutivité, ce qui le rend idéal pour les

entreprises ayant des besoins intermédiaires en matière de traitement de données.

Un entrepôt de données (data warehouse) est un système centralisé de gestion de données structurées qui stocke et gère de grandes quantités d'informations provenant de différentes sources au sein d'une organisation. Il est spécialement conçu pour faciliter l'analyse et la génération de rapports en permettant aux utilisateurs d'accéder aux données de manière efficace et organisée.

Les données dans un entrepôt de données sont nettoyées, transformées et structurées pour garantir leur cohérence et leur qualité, ce qui en fait un outil non négligeable pour la prise de décision et l'analyse de données dans les entreprises.

Ses principales caractéristiques sont les suivantes :

- **La performance de requêtes optimisée:** il exécute des requêtes complexes sur des grands ensembles de données rapidement, ce qui est essentiel pour les analyses en temps réel par exemple. De plus, le temps nécessaire pour traiter les requêtes est réduit, car l'entrepôt sépare le stockage du traitement des données pour une plus grande efficacité.
- **La gestion des données structurées:** il permet d'organiser, de stocker et de gérer de manière efficace des données qui sont formatées de manière ordonnée (ex: les données qui sont organisées selon un schéma prédéfini, comme des tables comportant des colonnes et des lignes).
- **La gouvernance et sécurité des données:** il offre des mécanismes solides pour la gestion et la protection des données. Par exemple, il permet une gestion stricte des droits d'accès aux données, réduisant ainsi le risque de fuites ou d'abus.

L'entrepôt est alimenté à partir des données d'exploitation via un processus ETL (Extract, Transform, Load) qui récolte les données aux différentes sources, effectue des traitements de consolidation de ces données, et les charge dans l'entrepôt.

Des outils de Business Intelligence s'appuient sur les données présentes dans l'entrepôt pour générer les rapports d'analyses et décisionnels.

L'entrepôt peut s'appuyer sur une infrastructure propre à l'entreprise, ou sur un cloud (Snowflake, Google BigQuery et Amazon Redshift).

2. Présentation de la structure actuelle

2.1 Description de l'existant

Les données sont structurées de la manière suivante :

- **Base de données transactionnelle (MySQL) :** Contient l'historique des commandes (50 000 en 2023), gérée par l'équipe de développement pour faire tourner le site e-commerce.
- **Fichiers Excel manuels :** Servent à suivre l'état des stocks (500 produits au catalogue) avec une mise à jour seulement hebdomadaire.
- **CRM externe isolé :** Héberge les profils et interactions des 3 000 clients actifs, mais n'est connecté ni à MySQL ni à Excel.
- **Rapports Google Sheets faits main :** Utilisés chaque mois de manière artisanale pour calculer le chiffre d'affaires et suivre l'activité.

2.2 Problématiques identifiées

Silos de données :

Les données de l'entreprise sont réparties dans plusieurs systèmes indépendants, tels que MySQL, le CRM, Excel et Google Sheets, sans interconnexion. Cette organisation en silos empêche de croiser facilement les informations et rend difficile l'obtention d'une vision globale de l'activité. Répondre à des questions comme le chiffre d'affaires par région, les produits les plus vendus ou les clients les plus fidèles nécessite des extractions et des rapprochements manuels entre plusieurs sources.

Données incohérentes et non fiables :

L'absence de synchronisation entre les différents systèmes entraîne des incohérences dans les données. Une même information, comme les coordonnées d'un client, peut être différente selon la source consultée. Les manipulations manuelles réalisées dans Excel ou Google Sheets augmentent également le risque d'erreurs, ce qui réduit la fiabilité des rapports et ralentit la prise de décision.

Processus manuels chronophages :

La production des rapports repose principalement sur des traitements manuels. Les données sont régulièrement exportées, copiées et mises à jour dans des fichiers Excel ou Google Sheets, ce qui représente un travail long et répétitif. De plus, ces tâches dépendent souvent de quelques collaborateurs maîtrisant ces fichiers, ce qui constitue un risque en cas d'absence ou de changement d'équipe.

Impossibilité d'analyses transverses :

Les analyses nécessitant le croisement de plusieurs sources de données ne peuvent pas être réalisées automatiquement. Pour répondre à des besoins tels que le chiffre d'affaires par région, le classement des produits les plus vendus ou l'identification des clients fidèles, il est nécessaire d'assembler manuellement des données issues de plusieurs systèmes. Cette approche limite les capacités d'analyse de l'entreprise, augmente le risque d'erreurs et empêche l'obtention rapide d'indicateurs fiables.

Pour résumer, l'analyse de l'existant met en évidence quatre problématiques majeures au sein d'ArtiSell : la présence de silos de données, des incohérences entre les différentes sources d'information, des processus de traitement largement manuels et l'impossibilité de réaliser des analyses transverses de manière automatisée. Ces limites nuisent à la qualité des données, ralentissent la prise de décision et réduisent la capacité de l'entreprise à exploiter efficacement son patrimoine informationnel.

Afin de répondre à ces enjeux, la mise en place d'un Data Warehouse constitue une solution adaptée. En centralisant les données provenant des différents systèmes, en les intégrant dans un modèle cohérent et en les mettant à disposition des outils de Business Intelligence, l'entreprise disposera d'une base fiable permettant de produire des analyses rapides, cohérentes et pertinentes.

3. Types de structures de Data Warehouse

La conception d'un Data Warehouse repose sur deux grandes approches méthodologiques historiques : l'approche Inmon (top-down) et l'approche Kimball (bottom-up). Ces deux visions, portées par les pionniers du domaine Bill Inmon et Ralph Kimball, diffèrent sur la philosophie de conception, la structure des données et la stratégie de déploiement. Une fois l'approche choisie, les données peuvent être organisées selon différents schémas : en étoile, en flocon ou en constellation¹.

Le choix entre l'approche Inmon et Kimball influence directement le type de schéma de modélisation utilisé. L'approche Inmon privilégie un schéma normalisé, dans lequel les données sont réparties dans plusieurs tables afin de limiter les redondances et de garantir leur cohérence (proche du flocon). A l'inverse, l'approche Kimball recommande un schéma dénormalisé, généralement en étoile, où certaines informations sont volontairement dupliquées afin de simplifier les requêtes et d'améliorer les performances des analyses décisionnelles.

3.1 Les principales approches de conception

Plusieurs approches permettent de concevoir un Data Warehouse. Le choix dépend principalement des besoins de l'entreprise, du volume des données à traiter et des objectifs d'analyse.

Approche de Bill Inmon (Top-Down)

L'approche proposée par Bill Inmon, considéré comme le “père du Data Warehouse”, consiste à construire un Data Warehouse centralisé qui regroupe l'ensemble

¹ Explication des schémas

<https://tutoriels.edu.lat/pub/cognos/data-warehouse-schemas/entrepot-de-donnees-schemas>

des données de l'entreprise. Les différents Data Marts destinés aux métiers (marketing, finance, logistique ...) sont ensuite créés à partir de cet entrepôt.

Dans cette approche les données sont modélisées selon un schéma hautement normalisé (jusqu'à la 3e forme normale, 3NF) pour éliminer au maximum la redondance.

Avantage:

- Vision globale et cohérente des données de l'entreprise.
- Données fortement normalisées (3NF), limitant la redondance et améliorant la cohérence.
- Excellente qualité et gouvernance des données.
- Facilite l'intégration de nouvelles sources.
- Convient aux grandes entreprises ayant de nombreux services.
- Permet de créer plusieurs Data Marts à partir d'une source unique et fiable.

Inconvénients :

- Temps de conception et de mise en œuvre important.
- Coût de développement plus élevé.
- Architecture plus complexe à concevoir et à maintenir.
- Les premiers résultats sont disponibles plus tardivement.

Approche de Ralph Kimball (Bottom-up)

L'approche de Ralph Kimball consiste à construire plusieurs Data Marts spécialisés répondant à des besoins métiers précis. Ceux-ci partagent des dimensions conformes (exemple: temps, client, produit) afin de constituer progressivement un Data Warehouse cohérent.

Dans cette approche, les données sont organisées selon un schéma dénormalisé (schéma en étoile) pour maximiser les performances de lecture et faciliter la compréhension par les utilisateurs métier.

Avantages :

- Déploiement rapide grâce aux Data Marts.
- Répond rapidement aux besoins métiers.
- Coût de mise en œuvre plus faible.
- Schémas en étoile simple à comprendre².
- Très bonnes performances pour les analyses décisionnelles (OLAP).

Inconvénients :

- Risque d'incohérences entre les Data Marts si la conception est mal maîtrisée.
- Évolution plus difficile lorsque les besoins deviennent très nombreux.
- Nécessite une bonne gestion des dimensions communes.

Le choix entre l'approche Inmon et Kimball influence directement le type de schéma de modélisation utilisé. L'approche Inmon privilégie un schéma normalisé (proche du flocon), tandis que l'approche Kimball recommande un schéma dénormalisé (étoile).


² Il est possible aussi de le faire en schéma en flocon, mais Kimball recommande généralement le schéma en étoile (plus simple à comprendre, moins de jointure, meilleurs perf pour les outils OLAP). <https://www.kimballgroup.com/data-warehouse-business-intelligence-resources/kimball-techniques/dimensional-modeling-techniques/star-schema-olap-cube/>

3.2 Les schémas de modélisation

Une fois l'approche de conception choisie, les données d'un Data Warehouse peuvent être organisées selon différents schémas de modélisation. Les trois principaux modèles sont le schéma en étoile, le schéma en flocon et le schéma en constellation.

Schéma en étoile (Star Schema)

Le schéma en étoile est le modèle de modélisation le plus répandu dans les systèmes décisionnels. Il est constitué d'une table de faits, contenant les mesures à analyser (ventes, chiffre d'affaires, quantités ...) , reliée directement à plusieurs tables de dimensions (clients, produits, temps, régions ...)



Dans le cadre d'ArtiSell, la table de faits pourrait contenir les informations relatives aux ventes, tandis que les tables de dimensions représenteraient les clients, les produits, les dates et les régions.

Avantages :

- Requêtes analytiques rapides grâce à un nombre limité de jointures
- Structure simple et facile à comprendre.
- Excellente compatibilité avec les outils de Business Intelligence.
- Modèle recommandé par Ralph Kimball pour les analyses décisionnelles.

Inconvénients :

- Redondance de données due à la dénormalisation des dimensions.
- Besoins de stockage généralement supérieurs à ceux d'un schéma en flocon.


Schéma en flocon (Snowflake Schema)

Le schéma en flocon est une évolution du schéma en étoile dans laquelle certaines tables de dimensions sont normalisées afin de réduire la redondance des données

Par exemple, au lieu de regrouper toutes les informations géographiques dans une seule table, celles-ci peuvent être réparties selon plusieurs niveaux :

Région => Département => Ville

Cette organisation permet de limiter la duplication des informations tout en améliorant la cohérence.



Avantages :

- Réduction de la duplication des données.
- Meilleure cohérence et intégrité des dimensions.
- Occupation mémoire généralement plus faible que le schéma en étoile (gain de stockage estimé à ~5-10%).

Inconvénients :

- Nombre de jointures plus important.
- Requêtes analytiques plus complexes et potentiellement moins performantes.
- Modèle plus difficile à comprendre pour les utilisateurs métier.


Schéma en constellation (Galaxy Schema)

Le schéma en constellation, également appelé Fact Constellation ou Galaxy Schema, est constitué de plusieurs tables de faits partageant une ou plusieurs dimensions communes.

Par exemple, un même Data Warehouse peut contenir plusieurs tables de faits représentant : Les ventes, les stocks ou encore les livraisons.

Ces tables peuvent partager des dimensions communes telles que le temps, les produits, les clients ou les régions.

Ce type de schéma est principalement utilisé dans les environnements décisionnels complexes où plusieurs processus métier doivent être analysés simultanément.



Avantages :

- Permet d'analyser plusieurs processus métier au sein d'un même Data Warehouse.
- Réutilisation des dimensions communes, limitant les duplications.
- Grande flexibilité pour répondre à des besoins analytiques variés.

Inconvénients :

- Architecture plus complexe à concevoir.
- Maintenance plus difficile.
- Requêtes analytiques plus complexes.

Un ensemble d'étoiles ou de flocons dans lequel les tables de faits se partagent certaines tables de dimensions forme un modèle "en constellation"

Au regard des besoins d'ArtiSell (réponses rapides, simplicité d'usage, coûts maîtrisés), le schéma en étoile selon l'approche Kimball apparaît comme la solution la plus adaptée.

3.3 Tableau : Comparaison des schémas de modélisation

Critère	Étoile	Flocon	Constellation
Structure	1 table de faits + dimensions dénormalisées	1 table de faits + dimensions normalisées	Plusieurs tables de faits + dimensions partagées
Nombre de jointures	Faible	Élevé	Moyen à élevé
Performance	Excellente	Moyenne à bonne	Bonne (selon la complexité des analyses)
Stockage	Plus importante (redondance)	Réduit (gain 5-10%)	Variable
Complexité	Faible	Moyenne	Élevée
Compréhension métier	Excellente	Bonne	Moyenne
Usage recommandé	Data Marts, BI analyses OLAP	Dimensions fortement hiérarchisées ou contraintes de stockage	Analyses de plusieurs processus métier (ventes, stocks, livraisons ...)

4. Infrastructure associée au Data Warehouse

Le Data Warehouse nécessite une infrastructure tant matérielle que logicielle :

- un ou plusieurs serveurs capables d'avoir l'espace de stockage, la mémoire et la puissance CPU nécessaires, avec le support, la maintenance et la gestion des sauvegardes associés
- les OS et les logiciels qui assurent les différents services du data warehouse, avec la gestion des mises à jour et des licences associée

Deux grandes options sont possibles :

- l'entreprise se dote de tous ces éléments matériels et logiciels et devient autonome pour le fonctionnement de son data warehouse, l'ensemble des données restent dans les locaux de l'entreprise
- l'entreprise utilise un service cloud pour porter l'intégralité de son data warehouse, toute l'infrastructure est alors portée par le fournisseur du service, les données ne sont alors pas hébergées par l'entreprise

Les avantages de la première option (on premise) sont les suivants :

- contrôle total sur tout (sans partage de responsabilité)
- performances non liées à celles de l'internet, mais à celles du réseau d'entreprise
- souveraineté des données garantie, conformité réglementaire

et ses inconvénients :

- investissements initiaux importants
- augmentation des capacités (stockage, CPU, mémoire) lourde et coûteuse

- personnel spécialisé nécessaire pour l'administration et la maintenance de l'infrastructure
- mise en oeuvre lente (approvisionnement, installation, prises de fonction)

L'option cloud a également ses avantages :

- le changement des capacités du data warehouse est simple et rapide
- il n'y a pas d'investissement matériel initial
- le délai de démarrage est très court
- les mises à jour sont faites régulièrement par le fournisseur
- la haute disponibilité est intégrée, pas d'impact d'une casse matérielle
- les outils d'analyse sont intégrés

mais aussi ses inconvénients :

- le coût est proportionnel à la consommation, la facilité d'utilisation peut inciter à une inflation des coûts par rapport aux prévisions initiales
- en cas de changement de solution, la sortie des données peut s'avérer coûteuse
- le bon fonctionnement est lié au débit internet
- l'hébergement des données n'est pas sous le contrôle de l'entreprise, ce qui peut poser des problèmes de conformité réglementaire

Dans la mesure où la souveraineté n'est pas un enjeu pour ArtiSell, que l'infrastructure actuelle n'est pas en mesure de s'agrandir facilement, que les employés n'ont actuellement pas les compétences requises pour gérer une infrastructure data warehouse, et que la volumétrie des données est modérée, l'option cloud semble bien adaptée. C'est aussi l'option la moins engageante pour démarrer l'activité.

Les fournisseurs actuels les plus connus sont :

Snowflake, Google BigQuery, Amazon Redshift, Databricks, ClickHouse Cloud.

Le choix pourra se faire en fonction des besoins à couvrir, de la structure choisie (cf. paragraphe précédent), du coût, des choix commerciaux de Artisell (partenariats, contrats déjà en cours, autres produits achetés, ...), de l'intégrabilité des outils ELT et BI choisis, d'expériences passées.

5. L'alimentation du Data Warehouse

L'alimentation d'un Data Warehouse constitue une étape essentielle d'un projet décisionnel. Elle regroupe l'ensemble des opérations permettant d'extraire les données des systèmes sources, de les transformer afin de garantir leur qualité et leur cohérence, puis de les intégrer dans le Data Warehouse pour les rendre exploitables par les outils décisionnels.

5.1 ETL et ELT : deux approches d'alimentation

Le choix entre **ETL** et **ELT** dépend des contraintes techniques, du volume de données et des besoins d'évolutivité de l'entreprise.

Deux approches principales permettent d'alimenter un Data Warehouse: **ETL** (Extract, Transform, Load) et **ELT** (Extract, Load, Transform)³.

5.1.1 ETL (Extract - Transform - Load)

Dans une architecture ETL, les données sont d'abord extraites des systèmes sources, puis transformées dans un moteur intermédiaire avant d'être chargées dans le Data Warehouse.

Fonctionnement :

- Extraction des données depuis les systèmes sources (base MySQL, CRM ...).
- Transformation des données (nettoyage, normalisation, calculs, contrôles de qualité).
- Chargement des données transformées dans le Data Warehouse.

³ <https://www.oracle.com/fr/database/elt-vs-etl/>

Avantages :

- Les données sont nettoyées avant leur intégration.
- Seules les données utiles sont stockées.
- Adapté aux environnements où les données doivent être transformées avant leur stockage.

Inconvénients :

- Pipeline plus long et plus complexe.
- Moins de flexibilité en cas d'évolution des besoins
- Les données brutes ne sont généralement pas conservées.

5.1.2 ELT (Extract - Load - Transform)

L'approche ELT consiste à charger les données brutes dans le Data Warehouse avant d'effectuer les transformations directement au sein de celui-ci.

Fonctionnement :

- Extraction des données depuis les systèmes sources.
- Chargement des données brutes dans le Data Warehouse.
- Transformation des données directement dans l'entrepôt.

Avantages :

- Conservation des données brutes.
- Plus grande flexibilité pour créer de nouvelles analyses.
- Exploitation de la puissance de calcul du Data Warehouse.
- Architecture généralement plus simple.

Inconvénients :

- Nécessite un Data Warehouse disposant de ressources suffisantes.
- Les transformations doivent être correctement organisées afin de préserver les performances.

5.1.3 Tableau comparatif

Critère	ETL	ELT
Ordre des opérations	Extract => Transform => Load	Extract => Load => Transform
Lieu des transformations	Serveur ETL	Data Warehouse
Conservation des données brutes	Généralement non	Oui
Flexibilité	Moyenne	Élevée
Évolutivité	Moyenne	Élevée
Complexité	Élevée	Faible
Coût	Élevé (outil ETL requis)	Réduit (pas d'outil ETL)

5.2 Les étapes d'alimentation

L'alimentation d'un Data Warehouse repose sur trois opérations fondamentales : l'extraction, la transformation et le chargement des données. Selon l'architecture retenue (ETL ou ELT), l'ordre des opérations peut varier. Cependant, chacune d'elles joue un rôle essentiel dans la préparation des données destinées aux analyses décisionnelles.

5.2.1 Extraction

L'extraction consiste à récupérer les données provenant des différents systèmes de l'entreprise. Dans le cas d'ArtiSell, les principales sources de données sont la base transactionnelle MySQL contenant les informations relatives aux produits et aux commandes, le CRM externe qui centralise les données clients ainsi que le fichier Excel utilisé pour le suivi des stocks. Cette étape permet d'identifier les données utiles et de les transférer vers le processus d'alimentation du Data Warehouse.

5.2.2 Transformation

La transformation regroupe l'ensemble des traitements appliqués aux données afin de les rendre exploitables pour les analyses décisionnelles.

Les principales opération réalisées sont :

- Suppression des doublons.
- Gestion des valeurs manquantes.
- Harmonisation des formats (dates, devises, codes postaux).
- Contrôle de cohérence des données.
- Création des tables de faits et des tables de dimensions. *

Selon l'architecture choisie, ces transformations peuvent être réalisées avant le chargement des données dans le Data Warehouse (ETL) ou directement au sein de celui-ci après leur chargement (ELT).

5.2.3 Chargement

Le chargement consiste à intégrer les données dans le Data Warehouse afin qu'elles puissent être exploitées par les outils décisionnels.

Dans une architecture ETL, cette étape intervient après les transformations, tandis que dans une architecture ELT, les données sont chargées avant d'être transformées.

La fréquence des chargements dépend des besoins de l'entreprise. Pour ArtiSell, une alimentation quotidienne apparaît suffisante afin de fournir des données régulièrement mises à jour à la direction marketing.

5.3 La qualité des données

La qualité des données constitue un élément essentiel d'un projet décisionnel. Des données incomplètes, incohérentes ou erronées peuvent conduire à des analyses faussées et à de mauvaises décisions.

Afin de garantir la fiabilité des informations intégrées au Data Warehouse, plusieurs traitements sont généralement réalisés lors du processus d'alimentation.

Le nettoyage consiste à corriger ou supprimer les données incorrectes. Il comprend notamment la suppression des doublons, la gestion des valeurs manquantes et la correction des erreurs de saisie.

La normalisation permet d'uniformiser les données afin qu'elles respectent un même format. Cela concerne par exemple les formats de dates, les devises, les codes postaux ou encore les unités de mesure.

L'enrichissement vise à ajouter des informations utiles pour les analyses. Il peut s'agir du calcul d'indicateurs métier, comme le chiffre d'affaires, ou de la création de nouvelles dimensions, telles que la dimension Temps.

Enfin, les contrôles de cohérence permettent de vérifier que les données respectent les règles métier et les relations définies dans le modèle de données. Ils garantissent notamment la validité des clés de liaison entre les différentes tables.


L'ensemble de ces traitements contribue à assurer la cohérence, la fiabilité et la qualité des données mises à disposition des utilisateurs, améliorant ainsi la pertinence des analyses et des décisions qui en découlent.

5.4 Le rôle de DBT

DBT (Data Build Tool) est un outil open source spécialisé dans la transformation des données au sein d'un Data Warehouse.

Contrairement à un outil ETL traditionnel, dbt est exclusivement dédié à la phase de transformation. Il ne réalise ni l'extraction ni le chargement des données, mais exécute directement des modèles SQL dans le Data Warehouse afin de préparer les données pour l'analyse. Il est ainsi principalement utilisé dans l'architecture ELT.

Son fonctionnement peut être résumé de la manière suivante :



DBT apporte plusieurs fonctionnalités particulièrement utiles dans un projet décisionnel :

- Développement des transformations sous forme de modèles SQL réutilisables.
- Gestion automatique des dépendances entre les transformations.
- Exécution des modèles dans le bon ordre.
- Tests automatisés de qualité des données.
- Génération automatique de la documentation et du data lineage⁴.
- Intégration avec Git afin de faciliter le travail collaboratif et le suivi des versions.

Grâce à ces fonctionnalités, DBT simplifie la maintenance des transformations et améliore la qualité des données exploitées dans le Data Warehouse.

⁴ Data lineage = traçabilité des données, c'est la capacité à suivre le parcours d'une donnée depuis sa source jusqu'à son utilisation finale.

5.5 Architecture recommandée pour ArtiSell

Au regard des besoins identifiés, une architecture **ELT** apparaît comme la solution la plus adaptée pour ArtiSell.

L'entreprise dispose de plusieurs sources de données hétérogènes : une base **MySQL** contenant les informations relatives aux **commandes** et aux **produits**, un **CRM** regroupant les données des **clients**, ainsi qu'un fichier **Excel** utilisé pour le suivi des **stocks**. L'extraction de ces données sera automatisée à l'aide de scripts **Python**, qui les chargeront dans le **Data Warehouse**. Les transformations seront ensuite réalisées directement au sein de celui-ci à l'aide de **dbt**, conformément au principe de l'architecture **ELT**.

Cette approche présente plusieurs avantages :

- Une architecture simple à mettre en œuvre et à maintenir.
- Une meilleure évolutivité en cas d'évolution des besoins métiers.
- La conservation des données brutes dans le Data Warehouse.
- Des transformations centralisées et versionnées grâce à **dbt**.
- Des tests automatisés garantissant la qualité des données.
- Une documentation générée automatiquement facilitant la maintenance du projet.

Cette architecture permettra à ArtiSell de centraliser l'ensemble de ses données au sein d'une **source de vérité unique** (*Single Source of Truth*). Les données ainsi fiabilisées et structurées pourront alimenter efficacement les outils décisionnels et répondre aux besoins de la direction marketing, notamment le suivi du chiffre d'affaires par région, l'identification des produits les plus vendus, l'analyse du comportement des clients ainsi que la production de rapports automatisés et fiables.

Pour conclure cette partie, l'alimentation du Data Warehouse constitue une étape essentielle dans la mise en place d'un système décisionnel performant. L'architecture ELT retenue pour ArtiSell permettra de centraliser, transformer et fiabiliser les données afin de répondre efficacement aux besoins analytiques de l'entreprise.

La section suivante présentera les principaux outils de Business Intelligence permettant d'exploiter ces données sous forme de tableaux de bord et d'indicateurs d'aide à la décision.

6. Outils d'analyses à partir du Data Warehouse

6.1 Outils de Business Intelligence (BI)

Sont des logiciels qui permettent d'analyser les données d'une entreprise en les restituant sous forme de tableaux de bord interactifs et de graphiques.

Les Avantages

- Prise de décision rapide : Accès à des tableaux de bord en temps réel pour décider sur la base de faits chiffrés.
- Vision globale : Regroupement des données de différents services (ventes, marketing, finances) dans un seul espace.
- Gain de temps : Automatisation des rapports, ce qui évite la création manuelle de tableaux Excel répétitifs.
- Identification des tendances : Anticipation des comportements du marché ou des clients grâce à l'analyse de l'historique.

Les Inconvénients

- Complexité technique : Nécessite une formation des équipes ou l'embauche de spécialistes pour configurer et utiliser correctement l'outil.

Tableaux de bord de vente Power BI



6.2 Outils Tableau

Tableau est l'un des logiciels de Business Intelligence et de visualisation de données les plus puissants du marché. Racheté par Salesforce, il est réputé pour sa capacité à transformer des volumes massifs de données complexes en graphiques et tableaux de bord interactifs et esthétiques.

Les Avantages

- Capacité visuelle exceptionnelle : Tableau offre la plus grande liberté de personnalisation graphique du marché. Il permet de créer des visualisations sur mesure (cartes géographiques complexes, diagrammes avancés) sans être bridé par des modèles rigides.

- Performance sur les grands volumes (Big Data) : Il gère très efficacement des millions de lignes de données en direct ou en mémoire via son moteur en colonne hyper-rapide.
- Exploration libre et intuitive (Glisser-déposer) : Pour les analyses à chaud (ad-hoc), l'interface permet de manipuler les variables par simple glisser-déposer pour découvrir des tendances cachées.

Les Inconvénients

- Coût élevé de licence : Tableau est plus cher que la majorité des concurrents (notamment Power BI). Le tarif démarre aux alentours de 70 à 75 \$/utilisateur/mois pour une licence Creator, ce qui représente un budget important pour les PME.
- Courbe d'apprentissage exigeante : S'il est facile de créer un graphique basique, maîtriser les calculs avancés (LOD - Level of Detail) et la modélisation demande une vraie expertise technique.
- Préparation de données limitée : Bien que Tableau Prep existe, Tableau n'est pas un véritable outil ETL. Il nécessite souvent que les données soient déjà bien structurées en amont (par exemple dans dbt ou un Data Warehouse).
- Absence de contrôle de version natif : Il est difficile de travailler à plusieurs en même temps sur le même rapport ou de suivre les modifications historiques comme avec du code.



Modèle E-commerce

Conclusion:

Pour le cas ArtiSell spécifiquement :

Je recommanderais :

Power BI pour la directrice marketing (facile, visuel)

7. Gestion des droits

Le data warehouse donne la possibilité de gérer les droits d'accès aux données entreposées.

Principes fondamentaux :

- RBAC (Rôles) : Grouper les utilisateurs par profil (ex. : analyste, finance, admin) plutôt que par individu.
- Moindre privilège : Donner uniquement les accès stricts nécessaires au travail de l'utilisateur.
- Grant / Revoke : Utiliser les commandes SQL standard pour autoriser (**GRANT**) ou interdire (**REVOKE**) des actions (SELECT, INSERT, etc.).

Niveaux de sécurité :

- Niveau objet : Bloquer ou autoriser l'accès à des tables ou des vues entières.
- Niveau ligne (RLS - Row-Level Security) : Filtrer les lignes visibles selon l'utilisateur (ex. : un responsable voit uniquement les données de sa région).
- Niveau colonne (CLS - Column-Level Security) : Masquer des informations sensibles comme les salaires ou les numéros de téléphone.

8. Maintenance et évolutivité

Le data warehouse étant hébergé par un cloud, les services associés sont maintenus et mis à jour par l'hébergeur, il n'y a pas d'infrastructure propre à maintenir. D'autre part, une évolution des besoins (capacité de stockage, puissance de traitement) est simple à traiter, l'hébergeur offrant cette possibilité à tout moment. Il reste donc la gestion des droits, des sauvegardes par un administrateur fonctionnel qui s'adapte aux évolutions des besoins de l'entreprise.

Il en est de même pour les traitements ETL via DBT et les services Power BI.

Le seul support à prévoir est donc celui lié aux traitements effectués par l'ETL en cas d'évolution des données ou des besoins métier, de même pour les rapports Power BI.

9. Ressources nécessaires à la solution

Tous les composants de la solution étant hébergés dans un cloud, les ressources se limitent donc aux éléments suivants :

- paiement de l'utilisation des services du cloud en fonction de leur consommation
- responsable de l'administration fonctionnelle du data warehouse (gestion des droits, suivi de la consommation d'espace, évolution de la structure des données en fonction de l'évolution des données opérationnelles et des besoins métier)
- un développeur des traitements ETL qui les fait évoluer en fonction des données sources et de la structure du data warehouse, et qui intervient en cas de problème d'alimentation des données ou de perte de leur qualité
- un développeur des rapports Power BI qui s'adapte aux évolutions de la structure du data warehouse et des besoins métier des analystes, qui soit également en mesure de former les analystes à l'utilisation de ces rapports

10. Conclusion

Cette étude a permis de répondre à la problématique d'ArtiSell: centraliser des données aujourd'hui dispersées entre MySQL, CRM, Excel et Google Sheets, pour produire des analyses fiables et rapides.

La solution proposée repose sur un Data Warehouse cloud, structuré en schéma en étoile (approche Kimball), alimenté selon une architecture ELT via dbt, et restitué aux équipes métier grâce à Power BI. Cette architecture cloud limite les investissements initiaux, délègue la maintenance à l'hébergeur et s'adapte facilement à la croissance de l'entreprise, tout en garantissant une gestion sécurisée des accès.

ArtiSell disposera ainsi d'une source de données unique, permettant d'obtenir en quelques clics des réponses: chiffre d'affaires par région, produits les plus vendus, fidélité client, qui nécessitaient auparavant plusieurs heures de traitement manuel.

11. Sitographie

OLTP et OLAP :

Yacine, «*Actualité techno - OLAP VS OLTP: Comment identifier la meilleure solution pour vos données ?*». [En ligne] Uzinakod, 21 mai 2024 [Consulté le 29/07/2026]
<https://www.uzinakod.com/blogue/meilleure-solution-donnees-olap-oltp>

Université de Marne-La-Vallée, «*Informatique décisionnelle (BI) : OLAP et la modélisation dimensionnelle*». [En ligne] s.d. [Consulté le 29/07/2026]
http://www-igm.univ-mlv.fr/~dr/XPOSE2009/informatique_decisionnelle_olap/

IBM, «*Qu'est-ce que l'OLAP (traitement analytique en ligne) ?*». [En ligne] s.d. [Consulté le 29/07/2026] <https://www.ibm.com/fr-fr/think/topics/olap>

Équipe Databricks, «*Qu'est-ce que l'OLAP ?*». [En ligne] s.d. [Consulté le 29/07/2026]
<https://www.databricks.com/fr/blog/what-is-olap>

Approche et schemas (Inmon, Kimball, étoile, flocon, constellation) :

Jonathan Neo «*Building a Kimball dimensional model with dbt*» [En ligne] Dbt labs, 20 avril 2023 [Consulté le 29/07/2026]
<https://docs.getdbt.com/blog/kimball-dimensional-model?version=2.0&name=v2>

Jérémy Robert «*Méthode de Kimball : Qu'est-ce que c'est ? Comment l'utiliser ?*» [En ligne] Liora.io, 18 février 2026 [Consulté le 29/07/2026]
<https://liora.io/methode-de-kimball-tout-savoir>

Tutoriels.edu.lat «*Entrepôts de données - Schémas*» [En ligne] s.d. [Consulté le 29/07/2026]
<https://tutoriels.edu.lat/pub/cognos/data-warehouse-schemas/entrepot-de-donnees-schemas>

Wikipédia «*Étoile (modèle de données)*» [En ligne] s.d. [Consulté le 29/07/2026]
[https://fr.wikipedia.org/wiki/%C3%89toile_\(mod%C3%A8le_de_donn%C3%A9es\)](https://fr.wikipedia.org/wiki/%C3%89toile_(mod%C3%A8le_de_donn%C3%A9es))

Équipe databricks «*Qu'est-ce qu'un schéma en étoile ?*» [En ligne] Databricks, s.d. [Consulté le 29/07/2026] <https://www.databricks.com/fr/blog/what-is-star-schema>

Wip4Tech «*Data Warehouses : Différences entre les approches Kimball et Inmon*» [En ligne] WIP4Tech consulting, 21 février 2024 [Consulté le 29/07/2024]
<https://www.wip4tech.com/data-warehouses-differences-entre-les-approches-de-kimball-et-inmon>

Raphael Kassel «*Bill Inmon: L'incroyable biographie du père des Data Warehouse*» [En ligne] Liora.io, 28 janvier 2026 [Consulté le 29/07/2026] <https://liora.io/bill-inmon-biographie>

Data Warehouse :

Hugo, «*Data Lake ou Data Warehouse: Quelle option pour gérer les données de votre entreprise ?*» [En ligne] Uzinakod, 22 janvier 2024 [Consulté le 29/07/2026] [Les différences principales entre Data Lake et Data Warehouse | Uzinakod](#)

Databricks «*Architecture du data warehouse*» [En ligne] s.d.[Consulté le 29/07/2026] <https://www.databricks.com/fr/discover/data-warehouse-architecture>

Université Marne-La-Vallée «*Entrepôt de données : Architecture technique*» [En ligne] s.d. [Consulté le 30/07/2026] <http://www-igm.univ-mlv.fr/~dr/XPOSE2005/entrepot/archi.html>

AWS «*Qu'est-ce qu'un entrepôt de données ?*» [En ligne] s.d. [Consulté le 29/07/2026] <https://aws.amazon.com/fr/what-is/data-warehouse/>

AI Brown «*Top 5 cloud data warehouses in 2026: Architecture, cost, and open-source*» [En ligne] Click House, mis à jour le 13 Avril 2026 [Consulté le 30/07/2026] <https://clickhouse.com/resources/engineering/top-5-cloud-data-warehouses>

ETL et ELT :

Oracle «*ELT versus ETL*» [En ligne] Oracle, s.d. [Consulté le 30/07/2026] <https://www.oracle.com/fr/database/elt-vs-etl/>

AWS «*Quelle est la différence entre ETL et ELT*» [En ligne] s.d. [Consulté le 29/07/2026] <https://aws.amazon.com/fr/what-is/data-warehouse/>

DBT :

Dbt labs «*What is dbt ?*» [En ligne] Dbt Labs, s.d. [Consulté le 30/07/2026] <https://docs.getdbt.com/docs/introduction>

Antoine Giannotta «*Pourquoi utiliser DBT dans sa stack d'outils ?*» [En ligne] DataBird, mis à jour le 19/03/2026 [Consulté le 30/07/2026] <https://www.data-bird.co/blog/pourquoi-utiliser-dbt>

Outils de Business Intelligence :

Eugenia Anello «*Les 9 meilleurs exemples de tableaux de bord Power BI*» [En ligne] Datacamp, mis à jour le 4 Octobre 2024 [Consulté le 30/07/2026] <https://www.datacamp.com/fr/blog/9-power-bi-dashboard-examples>