

BRIEF DBT

CONSTRUIRE UN DATA WAREHOUSE

CONTEXTE ET OBJECTIF

Suite a votre veille technologique sur ArtiSell, vous avez recommande la mise en place d'un Data Warehouse analytique.

Vous allez maintenant construire ce DWH sur le dataset Northwind une base OLTP complete representant une entreprise de commerce international.

Northwind Traders est une entreprise fictive qui importe et exporte des specialites alimentaires dans le monde entier. La base contient des donnees reelles de commandes, clients, produits et employes sur plusieurs années.

Planning :

jours	objectif	Question
1	setup + 8 modèles staging	1 à 7
2	intermediate + dimensions	8 à 12
3	fact_orders + dim_temps + tests	13 à 17
4	Documentation + requêtes analytiques	18 à 19
5	Rapport + présentation + bonus	20

Ceux qui ont fini les question avant la fin de la journée aident les collègues en difficulté

Les tables :

Customers, orders, order_details, products, categories, suppliers, employees, shippers

Setup de base & Administration base de donnée:

_ creation de l'environnement virtuel

_ installation via un requirements.txt de dbt-core et dbt-postgres

_ création de la database « northwind »

_ creation des roles (nologin) « northwind_readonly » et « northwind_dbt » avec les bons privilèges

<u>action</u> \ rôle	northwind_readonly	northwind_dbt
lire dans "public"	OUI	OUI
écrire dans "public"	NON	NON
supprimer dans "public"	NON	NON
créer des schémas (dbt_dev)	NON	OUI
créer des <u>vues</u> ... (dbt_dev)	NON	OUI

_ creation des user « analyste » mdp : 'analyste123'(hérite du northwind_readonly) & dbt_user mdp : 'dbt123' (hérite de northwind_dbt)

_ appliquer les même règles a toutes les futures tables créées dans 'public'

Partie 1 — Staging (Q1 a Q7)

A retenir : Règle du staging : un modele par table source. Pas de jointures. Uniquement du nettoyage : TRIM, LOWER, COALESCE, cast de types, renommage.

Q1 - Créer le fichier sources.yml dans models/staging/ declarant les 8 tables Northwind. Le nom de la source doit correspondre a ce que vous utiliserez dans source('northwind', 'customers').

Q2 - Créer le modele staging des clients. Nettoyer les colonnes texte avec TRIM, standardiser la casse.

Colonnes attendues : customer_id, company_name, contact_name, contact_title, city, country, phone

Q3 - Créer le modele staging des commandes. Typez les colonnes de façon cohérente. Ajouter une colonne is_shipped (TRUE si shipped_date n'est pas NULL).

Q4 - Créer le modèle staging des lignes de commande. Calculer une colonne `sous_total` = `unit_price` x `quantity` x (1 - `discount`).

Q5 - Créer le modèle staging des produits. Ajouter une colonne booléenne `en_stock` (TRUE si `units_in_stock` > 0).

Q6 - Créer les 4 staging restants. Pour `stg_employees` : concatener `first_name` et `last_name` en une colonne `full_name`.

Q7 – Vérifiez que les 8 vues sont créées dans la base de donnée et surtout le bon schéma via une commande `dbt`

Partie 2 — Intermediate

A retenir : Règle de l'intermediate : combine plusieurs staging. Pas de source(). Uniquement des ref(). Calculs plus complexes et jointures préparatoires.

Q8 - Joindre `stg_orders` et `stg_order_details` pour calculer par commande : `nb_articles`, `quantite_totale`, `montant_total`. Ajouter aussi `delai_livraison_jours` (`shipped_date` - `order_date`) et `is_on_time` (TRUE si `shipped_date` <= `required_date`, attention aux NULLs)

Q9 - Joindre `stg_products`, `stg_categories` et `stg_suppliers` pour enrichir chaque produit avec sa catégorie (`category_name`, `description`) et son fournisseur (`company_name`, `country`).

Q10 — `int_customers_stats.sql` — pour chaque client : nb commandes total, CA total, date première commande, date dernière commande, délai moyen entre commandes

Q11 — `int_employee_stats.sql` — pour chaque employé : nb commandes traitées, CA total, taux de livraison à temps, délai moyen de livraison

Q12 — `int_monthly_revenue.sql` — CA par mois avec `DATE_TRUNC`, nombre de commandes, panier moyen, variation vs mois précédent avec `LAG`

Q13 — `int_product_sales.sql` — pour chaque produit : quantité totale vendue, CA généré, nb commandes distinctes, stock restant depuis `stg_products`

PARTIE 3 — Marts

Q14 — Créer `dim_customers.sql` depuis `stg_customers`

Q15 — Créer `dim_products.sql` depuis `int_products_enriched` — ajouter colonne `gamme` (Entrée de gamme / Milieu de gamme / Premium)

Q16 — Créer `dim_employees.sql` et `dim_shippers.sql`

Q17 — Créer `dim_temps.sql` — extraire depuis les dates de commandes : jour, mois, année, trimestre, `annee_mois`, `est_weekend`

Q18 — Créer `fact_orders.sql` depuis `int_orders_enriched` — ajouter `montant_total_avec_frais`

PARTIE 4 — Tests de qualité

Q19 — Créer `models/staging/schema.yml` avec tests `not_null` et `unique` sur les clés primaires des 8 modèles `staging`

Q20 — Créer `models/marts/schema.yml` avec tests `relationships` entre `fact_orders` et `dim_customers`, `dim_employees`, `dim_shippers`

Q21 — Lancer `dbt test` et corriger toutes les erreurs jusqu'à ce que tous les tests passent

PARTIE 5 — Documentation et validation

Q22 — Ajouter des descriptions dans les `schema.yml`, générer `dbt docs generate` & `dbt docs serve`, capturer le `lineage graph`

Q23 — Écrire et exécuter les 5 requêtes analytiques de validation sur le DWH

Q24 — Lancer `dbt build` — tous les modèles ET tous les tests doivent passer en une seule commande

SCHEMAS

staging

table/vue	schema (à vous de les typer correctement)
stg_customers	customer_id, company_name, contact_name, contact_title, city, country, phone
stg_orders	order_id, customer_id, employee_id, ship_via, order_date, required_date, shipped_date, ship_city, ship_country, freight, is_shipped
stg_order_details	order_id, product_id, unit_price, quantity, discount, sous_total
stg_products	product_id, product_name, supplier_id, category_id, unit_price, units_in_stock, units_on_order, discontinued, en_stock
stg_categories	category_id, category_name, description
stg_suppliers	supplier_id, company_name, contact_name, city, country, phone
stg_employees	employee_id, full_name, title, hire_date, city, country
stg_shippers	shipper_id, company_name, phone

Intermediate

modèle	schéma
int_orders_enriched	order_id, customer_id, employee_id, ship_via, order_date, required_date, shipped_date, ship_city, ship_country, freight, is_shipped, is_on_time, delai_livraison_jours, nb_articles, <u>quantite_totale</u> , <u>montant_total</u>
int_products_enriched	product_id, product_name, unit_price, units_in_stock, units_on_order, discontinued, en_stock, category_name, category_description, supplier_name, supplier_country
int_customers_stats	customer_id, nb_commandes, ca_total, date_premiere_commande, date_derniere_commande, delai_moyen_entre_commandes
int_employee_stats	employee_id, nb_commandes_traitees, ca_total, taux_livraison_a_temps, delai_moyen_livraison_jours
int_monthly_revenue	mois, nb_commandes, ca_mensuel, panier_moyen, ca_mois_precedent, variation_pct
int_product_sales	sproduct_id, quantite_totale_vendue, ca_genere, nb_commandes_distinctes, stock_restant

Marts

modèle	schema
dim_customers	customer_id, company_name, contact_name, contact_title, city, country, phone
dim_products	product_id, product_name, unit_price, units_in_stock, units_on_order, discontinued, en_stock, category_name, category_description, supplier_name, supplier_country, gamme
dim_employees	employee_id, full_name, title, hire_date, city, country
dim_shippers	shipper_id, company_name, phone
dim_temps	date_id, jour, mois, annee, trimestre, annee_mois, est_weekend
fact_orders	order_id, customer_id, employee_id, ship_via, order_date, required_date, shipped_date, ship_city, ship_country, freight, is_shipped, is_on_time, delai_livraison_jours, nb_articles, <u>quantite_totale</u> , <u>montant_total</u> , <u>montant_total_avec_frais</u>

Bonus :

Modèle	Colonnes
mart_employee_performance	employee_id, full_name, title, country, ca_total, nb_commandes, panier_moyen, taux_livraison_a_temps, delai_moyen_jours, rang, pct_ca_total